FIAP × FORZY · CHALLENGE IA

Assistente de Manutenção Preditiva com IA Generativa

Sprint 4 — Generative IA & Advanced Net
Documentação Final da Solução

Detecção de anomalias, classificação de falhas e assistente conversacional com RAG (Retrieval-Augmented Generation) para apoio ao troubleshooting de motores elétricos.

Grupo 4M

Arthur Pedreca de Almeida Vasco	RM 565215
Bruno Lanchariche Fitipaldi Lopes	RM 564129
Gustavo Civita Gonçalves	RM 561932
Rafael de Paiva Ramos	RM 563978
Thiago Santana Danyluk	RM 562286

Novembro de 2026 · Versão 1.0 · Repositório: https://github.com/brunofitipaldi/forzy-assistente

Sumário

1. Visão geral da solução
2. Documentação dos dados
3. Arquitetura da solução
4. Documentação dos modelos de inteligência artificial
5. Documentação da arquitetura RAG
6. Documentação funcional do assistente
7. Testes e resultados
8. Manual de instalação e execução
9. Limitações e continuidade
10. Organização da entrega final

> **Como ler este documento.** Cada funcionalidade é marcada como `Implementado`, `Parcial` ou `Futuro`. Todos os números apresentados foram obtidos executando o código do repositório nesta versão; os comandos que reproduzem cada resultado estão indicados no texto e na seção 8.

> **Dados simulados.** A Forzy não disponibilizou histórico real de sensores até esta sprint. Por isso, **as leituras de sensores, os documentos técnicos e as ordens de serviço usados nesta solução são simulados** e foram produzidos pelo grupo. Os resultados validam o método e a arquitetura, e não representam desempenho em produção. Todo item simulado está identificado com `origem: SIMULADO`.

Resumo executivo

O projeto entrega um assistente conversacional que ajuda técnicos e planejadores de manutenção a responder três perguntas: *o ativo está fora do normal?*, *qual falha é mais provável?* e *o que devo verificar?*. Para isso, combina três camadas construídas ao longo das sprints: um classificador de falhas conhecidas (Random Forest, Sprint 2), um baseline operacional com detector de anomalias (Isolation Forest temporal, Sprint 3) e, nesta sprint, uma arquitetura RAG que recupera trechos de manuais, procedimentos e ordens de serviço e os entrega, junto com os dados dos sensores e as saídas dos modelos, a um modelo de linguagem executado localmente (Llama 3.1 8B via Ollama).

Indicador	Resultado	Como foi medido
Detector de anomalias	F1 0,947 · ROC-AUC 0,982 · falso alerta 4,24%	9.000 leituras de teste (30% finais de cada motor)
Classificador de falhas	F1 macro 0,728 · acurácia 0,823	mesmo período de teste, 4 classes
Recuperação de documentos	Hit@3 0,812 · MRR 0,719 · 6/6 perguntas fora do escopo bloqueadas	22 perguntas rotuladas
Cenários ponta a ponta	9 de 9 aprovados nas verificações automáticas; 7 de 9 corretos na avaliação manual	9 cenários com verificação automática

1. Visão geral da solução

1.1 Problema

Paradas não planejadas de motores elétricos interrompem a produção, geram custos de reparo emergencial e riscos de segurança. Os sinais de degradação (aumento de vibração, aquecimento, aumento de corrente e queda de rotação) costumam aparecer horas antes da falha, mas ficam dispersos entre a telemetria dos sensores, o histórico de manutenção e a documentação técnica. Na prática, o técnico precisa consultar várias fontes e interpretar gráficos para decidir o que inspecionar primeiro.

A solução reúne essas fontes em um único ponto de consulta em linguagem natural. O assistente identifica desvios em relação ao comportamento normal, sugere a falha conhecida mais compatível, recupera os procedimentos de troubleshooting pertinentes e apresenta as fontes usadas, deixando a decisão final com o profissional responsável.

1.2 Público-alvo

Perfil	Uso principal
Técnico / operador de manutenção	Consultar a situação de um motor, entender o alerta e seguir o procedimento de verificação
Planejador (PCM)	Priorizar inspeções pelo ranking da frota e consultar o histórico de ordens de serviço
Engenheiro de confiabilidade	Investigar padrões de falha, avaliar a qualidade dos modelos e recalibrar limiares
Equipe Forzy	Integrar a solução à plataforma de monitoramento de ativos e evoluí-la com dados reais

1.3 Benefícios esperados para a Forzy

- **Detecção antecipada:** no MOT-008, a partir das 16:05:30 o detector sinalizou alerta em 528 das 529 leituras seguintes, cerca de 26 minutos após o início da rampa de degradação simulada (15:39), quando a vibração ainda estava perto de 2,5 mm/s, no limite superior da faixa normal, e mais de quatro horas antes do pico de 8,1 mm/s (Figura 4.3).
- **Priorização objetiva:** o ranking por taxa de alertas e severidade orienta qual ativo inspecionar primeiro.
- **Menor tempo de diagnóstico:** dados, modelos, histórico e procedimento aparecem em uma única resposta, com citação das fontes.
- **Rastreabilidade e confiança:** cada resposta mostra os trechos consultados e registra a interação em log.
- **Privacidade e custo:** o LLM e os embeddings rodam localmente (Ollama), sem envio de dados operacionais para a nuvem e sem custo por consulta.

1.4 Escopo e funcionalidades entregues

Funcionalidade	Status	Observação
Classificação de falhas conhecidas (4 classes)	Implementado	Random Forest da Sprint 2, reavaliado nesta versão
Baseline operacional e detecção de anomalias	Implementado	Isolation Forest temporal da Sprint 3, consolidado em `src/anomalias.py`
Severidade, persistência e sensor de maior desvio	Implementado	Cortes P95/P97/P99 e sequências consecutivas de alertas
RAG com filtros por ativo e período	Implementado	Busca híbrida (embeddings + TF-IDF) com fusão RRF
Assistente conversacional com citação de fontes	Implementado	Interface Streamlit e linha de comando
Tratamento de ambiguidade, falta de informação e segurança	Implementado	Guardas determinísticas e aviso obrigatório
Painel da frota (ranking e séries temporais)	Implementado	Aba "Painel da frota" no Streamlit
Memória de conversa	Parcial	Lembra apenas o último ativo citado ("e esse motor?")
Pontuação em tempo real (streaming)	Futuro	Hoje as leituras são pontuadas em lote pelo pipeline
Estimativa de vida útil remanescente (RUL)	Futuro	Prevista na Sprint 1; depende de histórico real até a falha
Integração com dados reais, ERP e SCADA da Forzy	Futuro	Arquitetura preparada para troca da fonte de dados

1.5 Casos de uso principais

ID	Caso de uso	Exemplo de pergunta
UC1	Consultar a situação atual de um ativo	"Como está o MOT-008 agora?"
UC2	Entender um alerta e a falha provável	"O MOT-011 está esquentando? O que pode ser?"
UC3	Obter o procedimento de troubleshooting	"O que devo verificar segundo o procedimento?"
UC4	Consultar o histórico de manutenção	"O MOT-001 teve manutenção em março?"
UC5	Priorizar inspeções da frota	"Quais motores estão mais críticos agora?"
UC6	Consultar um período específico	"Como estava a vibração do MOT-019 entre 15h e 16h?"

1.6 Evolução ao longo das sprints

Sprint	Entrega	Situação nesta versão
1	Mapeamento de fontes e desenho dos pipelines de ML/DL e RAG	Base conceitual; as escolhas simplificadas na implementação estão justificadas nas seções 2, 5 e 9
2	Base sintética `motor.db`, EDA, Random Forest e agente com *function calling* (Groq)	Modelo e base reutilizados; o agente original foi mantido em `src/agente_sprint2_legado.py`
3	Baseline e detector de anomalias (Isolation Forest temporal)	Pipeline consolidado em `src/anomalias.py`; a reexecução reproduziu as métricas do relatório da Sprint 3
4	Base documental, RAG, assistente integrado, interface, testes e esta documentação	Entregue nesta sprint

2. Documentação dos dados

2.1 Fontes utilizadas

Fonte	Arquivo	Formato	Período	Volume	Origem
Telemetria dos sensores	`dados/motor.db` (tabela `leituras`)	SQLite	01/05/2026, 08:00:00 a 20:29:30	30.000 leituras (20 × 1.500)	SIMULADO (`gerar_banco.py`, seed 42)
Cadastro de ativos	`motor.db` (tabela `motores`)	SQLite	—	20 motores	SIMULADO
Registro de falhas	`motor.db` (`tipos_falha` e coluna `falha`)	SQLite	mesmo da telemetria	4 classes, rótulo por leitura	SIMULADO
Histórico de manutenção	`dados/historico_manutencao.csv`	CSV	09/01/2026 a 28/04/2026	23 ordens de serviço	SIMULADO
Documentação técnica	`docs_tecnicos/DOC-001…007.md`	Markdown com metadados	versão 1.0	7 documentos, 35 trechos	SIMULADO (DOC-007 derivado do projeto)
Saídas dos modelos	`modelos/sprint3/resultados_anomalias.csv`	CSV	mesmo da telemetria	30.000 linhas	Gerado pelo pipeline

2.2 Identificação dos ativos

Os 20 ativos são motores de indução de 3 CV, 2 polos, IP55, do mesmo fabricante e modelo, identificados pelas tags `MOT-001` a `MOT-020` (coluna `tag`, chave `motor_id`). A mesma tag é usada nos sensores, nas ordens de serviço, nos metadados dos documentos e nas perguntas ao assistente, o que permite filtrar todas as fontes por ativo.

2.3 Variáveis e unidades

Variável	Unidade	Nominal	Faixa normal (P1–P99 do baseline)	Descrição
`rotacao`	RPM	3600	3542,0 – 3658,3	Velocidade do eixo
`vibracao`	mm/s (RMS)	1,8	1,12 – 2,50	Vibração na carcaça
`temperatura`	°C	65	57,92 – 71,99	Temperatura de carcaça
`corrente`	A	11,5	10,10 – 12,91	Corrente de alimentação
`timestamp`	ISO 8601	—	intervalo de 30 s	Data e hora da leitura
`falha`	código	—	0 Normal · 1 Desbalanceamento · 2 Superaquecimento · 3 Falha Mecânica	Rótulo por leitura (gabarito da simulação)

Distribuição dos rótulos: 24.890 leituras normais (82,97%), 2.089 de desbalanceamento (6,96%), 1.977 de superaquecimento (6,59%) e 1.044 de falha mecânica (3,48%). Dez motores operam normalmente durante todo o período; os outros dez desenvolvem uma falha com rampa progressiva que começa entre 60% e 80% da série (por exemplo, MOT-008 com falha mecânica a partir das 15:39:30).

2.4 Ordens de serviço e documentos técnicos

O histórico de manutenção tem as colunas `os_id, tag, data_abertura, data_fechamento, tipo` (preventiva, corretiva ou inspeção), `falha_relacionada, descricao, causa_raiz, acao, horas_parada, status, origem`. As ordens foram escritas para serem coerentes com o modo de falha simulado de cada motor (por exemplo, troca de rolamento no MOT-008 e problema de tensão no MOT-011).

Documento	Tipo	Conteúdo
DOC-001	manual	Identificação, valores nominais, limites de alarme, instalação, rolamentos, relação sensor × falha
DOC-002	procedimento	POP de troubleshooting de desbalanceamento e vibração elevada
DOC-003	procedimento	POP de superaquecimento e sobrecorrente
DOC-004	procedimento	POP de falha mecânica (rolamentos, desalinhamento, roçamento)
DOC-005	plano	Plano de manutenção preventiva e uso do monitoramento preditivo
DOC-006	segurança	Requisitos de segurança (NR-10/NR-12, bloqueio, situações de parada imediata)
DOC-007	guia	Interpretação de percentil, severidade, persistência e saídas dos modelos

Os documentos são simulados e **não reproduzem manuais oficiais de fabricantes**. Os limites de alarme foram definidos de forma coerente com a base sintética, para que o assistente possa cruzar leituras e procedimentos.

2.5 Tratamentos realizados

- **Qualidade:** verificação de ausentes (zero) e de duplicidades por motor/timestamp (zero).
- **Ordenação temporal** por motor e timestamp antes de qualquer janela ou divisão.
- **Divisão cronológica** por motor, sem embaralhamento, para evitar vazamento do futuro (detalhes na seção 4).
- **Padronização** com `StandardScaler` ajustado somente no treino.
- **Features temporais causais**: média, desvio e variação em janela das últimas 10 leituras (5 minutos).
- **Outliers** não foram removidos, porque representam justamente o fenômeno procurado.
- **Categorias** `fabricante` e `modelo` descartadas por terem variância zero.
- **Documentos:** extração de metadados do cabeçalho, divisão por seção, descarte de trechos curtos e do aviso de simulação (seção 5).

2.6 Limitações dos dados

- Todos os dados são simulados; o comportamento real tem variações de carga, partidas, ambiente e ruído de sensor que não estão presentes.
- Há apenas um dia de operação (12,5 h por motor) e um único modelo de motor.
- As falhas seguem rampas lineares conhecidas, o que torna a detecção mais fácil do que na operação real.
- O histórico de OS é anterior ao período dos sensores, então não há OS registrando as falhas de 01/05.
- Em relação ao planejado na Sprint 1 (SCADA, ERP, ~50 variáveis por equipamento, 200 a 400 documentos), a base implementada é muito menor; a substituição pelas fontes reais é a principal ação de continuidade (seção 9).

3. Arquitetura da solução

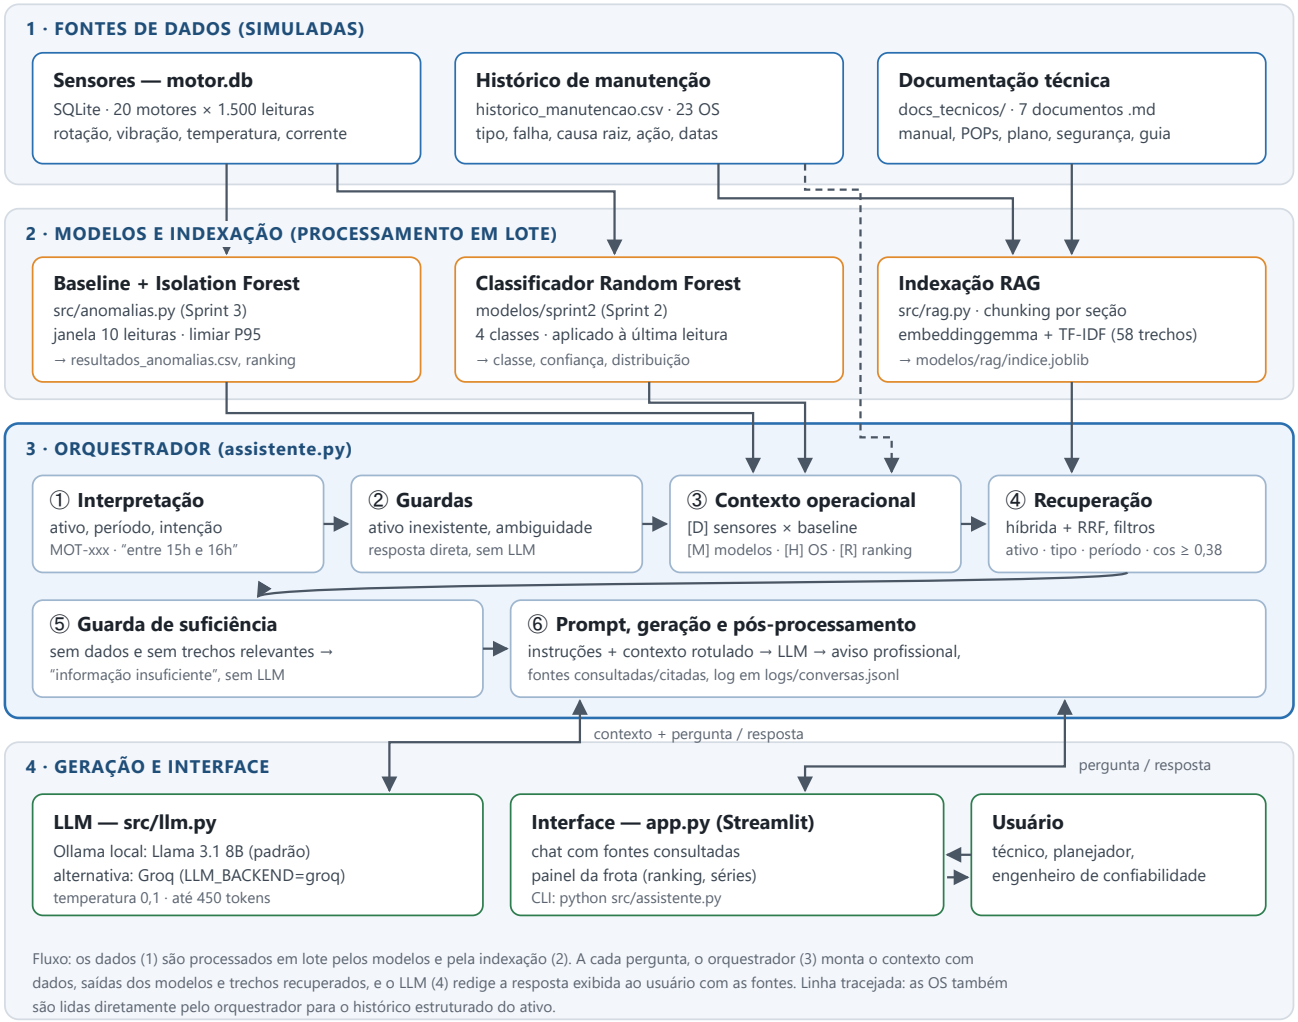


Figura 3.1 — Arquitetura e fluxo de informações, da entrada dos dados até a resposta ao usuário.

3.1 Componentes e responsabilidades

Componente	Arquivo	Tecnologia	Responsabilidade
Base de sensores	`dados/motor.db`	SQLite	Leituras, cadastro de ativos e tipos de falha
Pipeline de anomalias	`src/anomalias.py`	scikit-learn	Baseline, features temporais, Isolation Forest, limiar P95, severidade, persistência, ranking
Classificador de falhas	`modelos/sprint2/*.joblib`	scikit-learn	Classe de falha mais provável e distribuição de probabilidades
Indexação RAG	`src/rag.py`	Ollama (embeddinggemma), scikit-learn (TF-IDF)	Chunking, metadados, índice híbrido, busca com filtros
Dados operacionais	`src/dados_operacionais.py`	pandas	Resumo de sensores × baseline, saídas dos modelos, ranking e histórico de OS
Orquestrador	`src/assistente.py`	Python	Interpreta a pergunta, aplica guardas, monta o contexto, chama o LLM e pós-processa
Cliente de LLM	`src/llm.py`	Ollama (Llama 3.1 8B) ou Groq	Geração de texto e embeddings
Interface	`app.py`	Streamlit	Chat, exibição de fontes e painel da frota
Testes	`testes/*.py`	Python	Avaliação da recuperação e cenários ponta a ponta

3.2 Fluxo de uma pergunta

1. **Entrada:** o usuário digita a pergunta no Streamlit (ou no terminal); opcionalmente escolhe um ativo em foco.
2. **Interpretação:** o orquestrador extrai as tags de ativos (`MOT-008`, "motor 8"), o período ("entre 15h e 16h", "às 20:19", "últimos 30 minutos", "em março") e a intenção (situação, histórico, procedimento, frota).
3. **Guardas determinísticas:** ativo inexistente → resposta direta; pergunta sobre "o motor" sem tag → pedido de esclarecimento (sem chamar o LLM).
4. **Contexto operacional:** para cada ativo, resume as leituras do período e as compara com o baseline, consulta as saídas do detector de anomalias (percentil, severidade, persistência, sensor de maior desvio), aplica o classificador à última leitura e busca as OS.
5. **Recuperação:** a pergunta é enriquecida com a falha provável e o sensor de maior desvio e enviada ao índice híbrido, filtrado pelo ativo.
6. **Guarda de suficiência:** sem dado operacional e sem trecho acima do limiar de relevância, o assistente responde que não há informação suficiente.
7. **Geração:** o LLM recebe as instruções do sistema e o contexto rotulado com IDs (`[D1]`, `[M1]`, `[H1]`, `[DOC-003#3]`).
8. **Pós-processamento:** inclusão do aviso de avaliação profissional quando necessário, lista de fontes consultadas, marcação das fontes citadas e registro em `logs/conversas.jsonl`.

3.3 Integração entre os modelos das sprints anteriores e o assistente

Na Sprint 2, o agente chamava o classificador por *function calling*: o LLM decidia quando chamar a ferramenta e preenchia os quatro valores de sensores digitados pelo usuário. Nesta sprint a integração foi invertida: o **orquestrador consulta os modelos antes da geração** e entrega ao LLM os resultados já calculados como blocos de contexto. A decisão foi tomada por dois motivos: o fluxo deixa de depender da capacidade do LLM de escolher e preencher ferramentas corretamente, ponto sensível em modelos locais pequenos; e o assistente agora consulta os dados históricos do ativo, sem depender de o usuário digitar as leituras. A comparação experimental entre os dois modos de integração não foi feita e fica registrada como melhoria futura. O resultado é um fluxo determinístico, testável e auditável, em que o LLM fica responsável apenas por redigir a resposta a partir de evidências.

Modelo	Entrada no assistente	Bloco de contexto
Baseline (Sprint 3)	médias, desvios e P1/P99 por sensor	`[D#]`: valor atual, média, mín, máx, faixa normal, desvio padronizado
Isolation Forest temporal (Sprint 3)	saídas por leitura em `resultados_anomalias.csv`	`[M#]`: percentil, severidade, persistência, sensor de maior desvio, alertas no período
Random Forest (Sprint 2)	última leitura do período	`[M#]`: classe, confiança, distribuição, marcação de incerteza (< 60%)
Ranking (Sprint 3)	todas as leituras do período	`[R1]`: ativos por taxa de alertas e percentil máximo

3.4 Tecnologias

Python 3.14 · scikit-learn 1.8 · pandas 3.0 · NumPy 2.4 · SQLite · Ollama 0.40 com **Llama 3.1 8B** (quantização Q4) para geração e **embeddinggemma** (768 dimensões) para embeddings · Streamlit 1.58 · Matplotlib · Playwright (apenas para capturas de tela das evidências). O backend alternativo Groq (Llama 3.1 8B Instant), usado na Sprint 2, continua suportado por variável de ambiente.

4. Documentação dos modelos de inteligência artificial

4.1 Classificador de falhas (Sprint 2)

Item	Descrição
Tarefa	Classificação multiclasse do estado da leitura: Normal, Desbalanceamento, Superaquecimento, Falha Mecânica
Variáveis	`rotacao, vibracao, temperatura, corrente` (leitura pontual)
Preparação	StandardScaler ajustado no treino; categóricas sem variância descartadas
Divisão	Cronológica por motor: 70% iniciais para treino (21.000) e 30% finais para teste (9.000)
Algoritmo	RandomForestClassifier (150 árvores, profundidade máxima 14, `class_weight='balanced'`, random_state 42)
Referência	Regressão logística balanceada, com desempenho inferior
Justificativa	Captura interações não lineares (temperatura e corrente subindo juntas), é robusto e interpretável; o balanceamento por pesos foi preferido ao SMOTE porque este interpolaria leituras de instantes diferentes

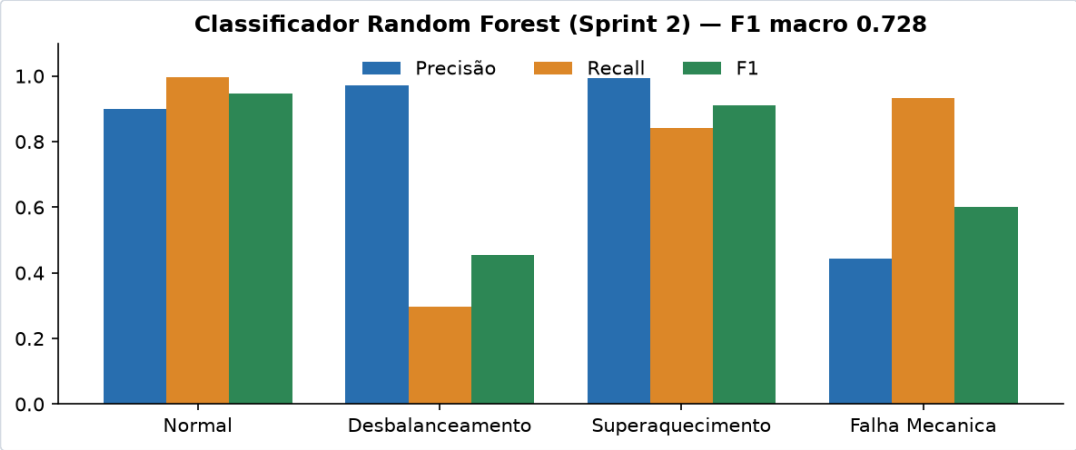


Figura 4.1 — Precisão, recall e F1 por classe no período de teste (`python src/avaliar_classificador.py`).

Classe	Precisão	Recall	F1	Suporte
Normal	0,900	0,996	0,946	4.647
Desbalanceamento	0,972	0,296	0,454	1.774
Superaquecimento	0,993	0,842	0,911	1.679
Falha Mecânica	0,443	0,932	0,601	900
Macro / acurácia	**F1 macro 0,728 · acurácia 0,823**			9.000

Análise. O ponto fraco é o Desbalanceamento: 1.043 das 1.774 leituras dessa classe foram previstas como Falha Mecânica, porque as duas falhas elevam a vibração e derrubam a rotação. Por isso o assistente apresenta a confiança do classificador, marca como *incerto* abaixo de 60% e trata a classe prevista como hipótese. A ablação da Sprint 2 com features de janela elevou o F1 macro para cerca de 0,97, mas não foi adotada no modelo entregue porque, na época, o agente recebia apenas uma leitura pontual. Com o assistente atual, que já consulta o histórico do ativo, essa versão passa a ser viável e é uma melhoria prioritária.

4.2 Baseline operacional (Sprint 3)

O baseline tem duas camadas. A estatística registra média, desvio e percentis P1/P99 de cada sensor no período normal de treino (tabela 2.3) e é usada para explicar o desvio de cada sensor. A multivariada é o próprio Isolation Forest, que aprende combinações normais entre os sensores que limites independentes não representam. Como os

20 motores são idênticos, adotou-se um baseline global; a separação por ativo é uma evolução prevista para dados reais.

4.3 Detector de anomalias — Isolation Forest temporal (Sprint 3)

Item	Descrição
Abordagem	Semissupervisionada: aprende somente a operação normal; os rótulos de falha não entram como feature
Variáveis (16)	4 sensores + média, desvio-padrão e variação (delta) em janela causal de 10 leituras (5 min) para cada sensor
Partições	Treino: 55% iniciais de cada motor (16.500 leituras, todas normais) · Calibração: 55–70%, apenas normais (3.743) · Teste: 30% finais (9.000)
Algoritmo	IsolationForest (300 árvores, `max_samples='auto'`, random_state 42); score = `−score_samples`
Limiar	Percentil 95 dos scores da calibração normal = **0,4944**
Saídas	Score, percentil em relação à calibração, alerta, severidade, persistência e sensor de maior desvio

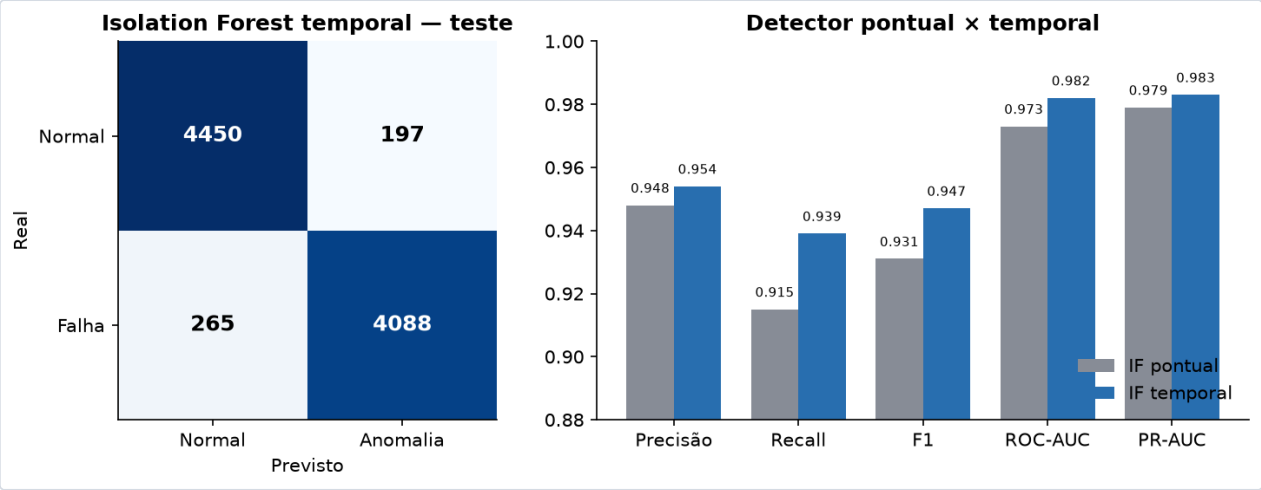


Figura 4.2 — Matriz de confusão do detector temporal e comparação com o detector pontual (`python src/anomalias.py`).

Modelo	Precisão	Recall	F1	ROC-AUC	PR-AUC	Falso alerta
Isolation Forest pontual (4 features)	0,948	0,915	0,931	0,973	0,979	4,69%
Isolation Forest temporal (16 features)	**0,954**	**0,939**	**0,947**	**0,982**	**0,983**	**4,24%**

Escolha. A versão temporal melhorou todas as métricas: as janelas capturam a tendência das rampas de degradação, que uma leitura isolada ainda confunde com ruído. Dos 4.353 eventos de falha do teste, 4.088 foram detectados; 197 das 4.647 leituras normais geraram alerta. As métricas são binárias (normal × anomalia) e não são diretamente comparáveis ao F1 macro multiclasse do classificador.

Severidade e persistência. Normal abaixo do P95; Atenção entre P95 e P97; Alta entre P97 e P99; Crítica a partir do P99. Alertas consecutivos do mesmo motor formam sequências: 1–2 leituras = pontual, 3–9 = curta, 10 ou mais (≥ 5 min) = persistente. No teste, 3.943 dos 4.285 alertas foram persistentes, 134 curtos e 208 pontuais; a vibração foi o sensor de maior desvio em 2.538 alertas.

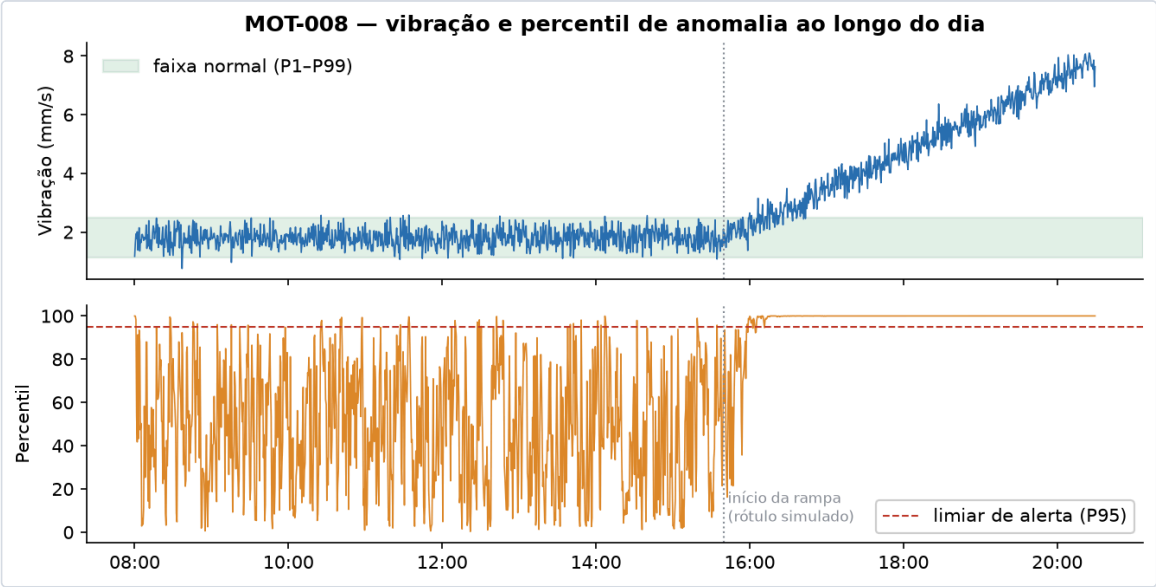


Figura 4.3 — MOT-008: a vibração deixa a faixa normal após o início da rampa simulada (15:39) e o percentil fica acima do limiar de forma persistente.

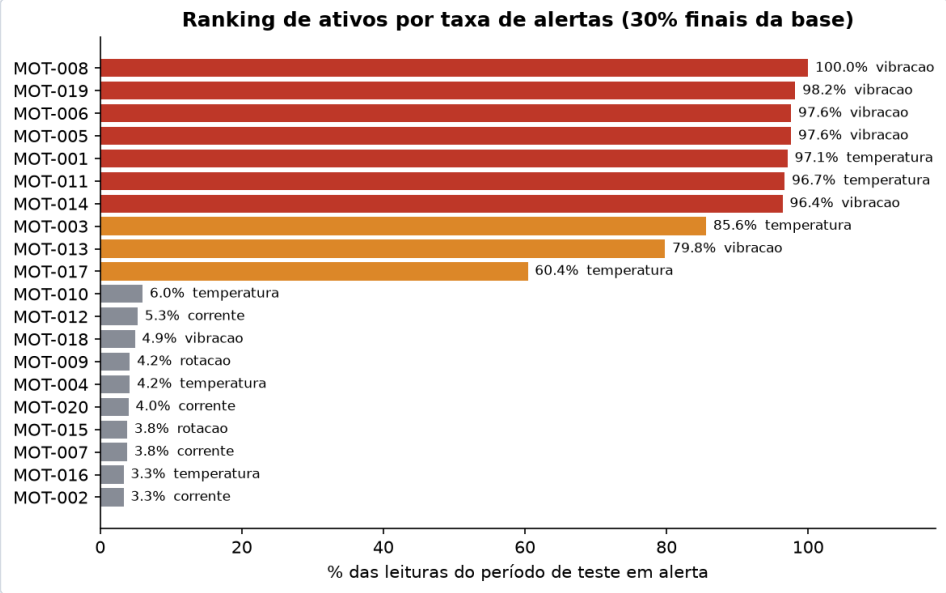


Figura 4.4 — Ranking de ativos por taxa de alertas no período de teste, com o sensor de maior desvio.

> **Reprodutibilidade.** O código da Sprint 3 foi consolidado em `src/anomalias.py`. A reexecução sobre o mesmo `motor.db` reproduziu exatamente as métricas, o limiar (0,4944) e a matriz de confusão do relatório da Sprint 3. A única diferença é a contagem de alertas curtos e pontuais (134/208 contra 136/206), porque os cortes de persistência foram fixados explicitamente nesta versão (3 e 10 leituras).

5. Documentação da arquitetura RAG

5.1 Preparação e indexação dos documentos

1. **Catálogo com metadados:** cada documento técnico tem um cabeçalho com `doc_id, titulo, tipo, ativos, versao, origem`. O campo `ativos` vale `todos` ou lista tags específicas.
2. **Chunking por seção:** o texto é dividido nos títulos de seção (`## `), preservando o contexto semântico de cada procedimento. Seções com mais de 1.200 caracteres são subdivididas por parágrafo, com sobreposição de um parágrafo; trechos com menos de 60 caracteres e o aviso de "documento simulado" não são indexados.
3. **Ordens de serviço:** cada OS vira uma ficha textual ("Ordem de serviço OS-2026-0009 do motor MOT-008, tipo corretiva…") com metadados de ativo e data.
4. **Índice híbrido** com 58 trechos (35 de documentos e 23 de OS):
   - *Denso:* embeddings **embeddinggemma** (768 dimensões, normalizados em L2), com os prefixos recomendados pelo modelo para documento e consulta;
   - *Léxico:* TF-IDF de palavras (unigramas e bigramas, sem acentos e sem *stopwords*) + TF-IDF de n-gramas de caracteres (3 a 5), que tolera variações como "superaquecido/superaquecimento".
5. **Persistência:** o índice é salvo em `modelos/rag/indice.joblib` (`python src/rag.py --indexar`).

5.2 Recuperação do contexto

- **Fusão:** as listas densa e léxica são combinadas por *Reciprocal Rank Fusion* (RRF, k = 60), técnica prevista na Sprint 1.
- **Expansão de consulta:** sinônimos do domínio são acrescentados à busca léxica ("esquentando" → temperatura/superaquecimento; "trepidando" → vibração; "amperagem" → corrente).
- **Consulta enriquecida:** quando o ativo está em alerta, a falha provável (se o classificador não estiver incerto) e o sensor de maior desvio são acrescentados à pergunta, para que o procedimento correto seja recuperado mesmo quando o usuário não cita o sintoma.
- **Filtros:** por **ativo** (só documentos gerais ou daquele ativo), por **tipo** de documento e por **período** (data de abertura das OS). As leituras de sensores também são filtradas pelo período interpretado na pergunta; sem período, usa-se os últimos 30 minutos da base.
- **Porta de relevância:** um trecho só vira evidência se a similaridade de cosseno com a pergunta for ≥ **0,38**. Sem embeddings disponíveis, o sistema cai para busca só léxica com limiar próprio.
- **Top-k:** até 3 trechos de documentos por resposta, além dos blocos operacionais.

5.3 Dados operacionais e resultados dos modelos no contexto

Os dados estruturados não passam pelo índice vetorial: são consultados diretamente e inseridos como blocos rotulados, o que evita erros de recuperação em valores numéricos. Exemplo real do bloco enviado ao LLM para o MOT-008:

```
[D1] Ativo MOT-008 | período 2026-05-01 19:59:30 a 2026-05-01 20:29:30 (61 leituras de 30 s)
- Rotação: atual 3267.9 RPM (média 3316.94, mín 3240.1, máx 3381.0); faixa normal do baseline 3542.0–3658.3 RPM; desvio atual -13.4 desvios-padrão
- Vibração: atual 7.64 mm/s (média 7.54, mín 6.78, máx 8.1); faixa normal do baseline 1.12–2.5 mm/s; desvio atual +19.5 desvios-padrão
- Temperatura: atual 89.82 °C (média 84.17, mín 76.03, máx 90.11); faixa normal do baseline 57.92–71.99 °C; desvio atual +8.3 desvios-padrão
- Corrente: atual 15.47 A (média 15.15, mín 13.26, máx 16.61); faixa normal do baseline 10.1–12.91 A; desvio atual +6.6 desvios-padrão

[M1] Detector de anomalias (Isolation Forest temporal) para MOT-008:
- última leitura 2026-05-01 20:29:30: percentil 100.0, severidade Crítica, persistência Persistente, sensor de maior desvio: Vibração
- alertas no período: 61 de 61 leituras (100.0%); primeiro alerta no período: 2026-05-01 19:59:30; sequência de alertas em curso desde: 2026-05-01 16:12:00; severidade máxima: Crítica
Classificador de falhas conhecidas (Random Forest) na última leitura: Falha Mecânica com confiança 77%; distribuição Normal 6%, Desbalanceamento 7%, Superaquecimento 11%, Falha Mecânica 77%
```

5.4 Modelos utilizados

Função	Modelo	Configuração
Geração	Llama 3.1 8B Instruct (Ollama, Q4_0)	temperatura 0,1 · máx. 450 tokens · contexto 8.192 tokens
Geração (alternativa)	Llama 3.1 8B Instant (Groq)	`LLM_BACKEND=groq`
Embeddings	embeddinggemma (Ollama)	768 dimensões, normalização L2, similaridade de cosseno

Comparação de modelos de geração. O Llama 3.2 3B foi testado com a mesma pergunta sobre o MOT-008. Ele respondeu em 114 s (o Llama 3.1 8B levou de 93 a 213 s nos cenários da seção 7, em CPU), mas afirmou que "a causa raiz é o desalinhamento de 0,12 mm", informação que vinha de uma OS de março e não da condição atual. Por priorizar fidelidade às fontes, o grupo manteve o Llama 3.1 8B como padrão.

5.5 Instruções de geração

O prompt de sistema (em `src/assistente.py`) define as regras abaixo; a instrução de citação é repetida ao final da mensagem do usuário, porque modelos pequenos seguem melhor a última instrução recebida.

1. Usar somente o contexto; não inventar valores, peças, normas ou procedimentos.
2. Citar a fonte entre colchetes após cada afirmação, com os IDs do contexto.
3. Dizer claramente quando a informação não estiver no contexto.
4. Alerta de anomalia não é falha confirmada; percentil não é probabilidade; sensor de maior desvio é heurística.
5. Classificador com confiança abaixo de 60% deve ser tratado como hipótese.
6. Nunca orientar religamento, desmontagem ou intervenção elétrica; intervenções são de profissional habilitado.
7. Formato: **Situação**, **Diagnóstico provável** e **Ações recomendadas**, em até 220 palavras.

5.6 Apresentação das fontes

- **No texto:** citações inline como `[M1]` e `[DOC-004#3]`.
- **No rodapé:** lista "Fontes consultadas" com ID e título de todos os blocos entregues ao LLM.
- **Na interface:** painel expansível com o texto de cada fonte, o tipo (dados de sensores, resultado de modelo, histórico, documento técnico), a relevância do trecho e a marca ✅ quando a fonte foi citada na resposta.

5.7 Avaliação da recuperação

Foram rotuladas 16 perguntas do domínio, cada uma com o documento esperado, e 6 perguntas fora do escopo (`python testes/avaliar_recuperacao.py`).

Configuração	Hit@1	Hit@3	MRR	Fora do escopo bloqueadas
Somente léxica (TF-IDF), limiar 0,10	0,438	0,812	0,642	2 de 6
Híbrida (embeddings + TF-IDF, RRF), limiar 0,38	**0,625**	**0,812**	**0,719**	**6 de 6**

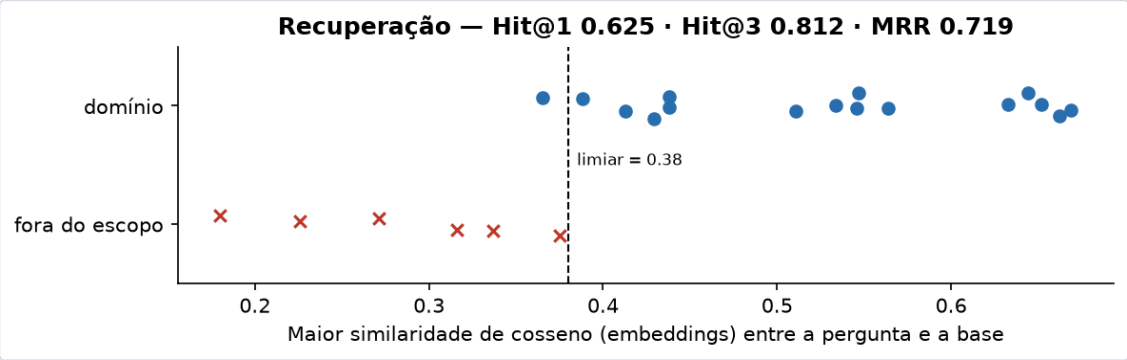


Figura 5.1 — Maior similaridade entre cada pergunta e a base. O limiar separa as perguntas fora do escopo, ao custo de duas perguntas válidas ficarem abaixo dele.

Análise. A busca híbrida melhorou a posição do documento correto e passou a rejeitar todas as perguntas fora do escopo. As faixas de similaridade se sobrepõem entre 0,36 e 0,38, então o limiar é um compromisso: duas perguntas válidas (“quem pode medir o isolamento…”, “troca de rolamento no histórico”) ficaram abaixo dele. A segunda é coberta pela consulta estruturada do histórico quando o ativo é informado. Como o conjunto é pequeno, o limiar deve ser recalibrado com mais perguntas reais.

6. Documentação funcional do assistente

6.1 Funcionalidades disponíveis

- **Chat em linguagem natural** sobre sensores, anomalias, falhas prováveis, histórico de manutenção e procedimentos.
- **Filtro de ativo** na barra lateral (opcional) e interpretação automática de tags e períodos na pergunta.
- **Fontes consultadas** em cada resposta, com o texto do trecho e a indicação das fontes citadas.
- **Perguntas de exemplo** clicáveis e botão para limpar a conversa.
- **Painel da frota:** ranking de ativos por alertas e gráficos do percentil de anomalia e de cada sensor ao longo do tempo.
- **Indicadores de estado:** modelo de linguagem em uso, disponibilidade do Ollama e período coberto pela base.

6.2 Etapas de utilização da interface

1. Inicie o Ollama e execute `streamlit run app.py`; o navegador abre em `http://localhost:8501`.
2. Confira na barra lateral se o Ollama aparece como disponível.
3. (Opcional) Escolha um ativo em foco; caso contrário, informe a tag na pergunta.
4. Digite a pergunta ou clique em um exemplo. A resposta leva de 1 a 4 minutos em CPU.
5. Leia a resposta e abra “Fontes consultadas” para verificar as evidências.
6. Use a aba “Painel da frota” para ver o ranking e os gráficos do ativo.

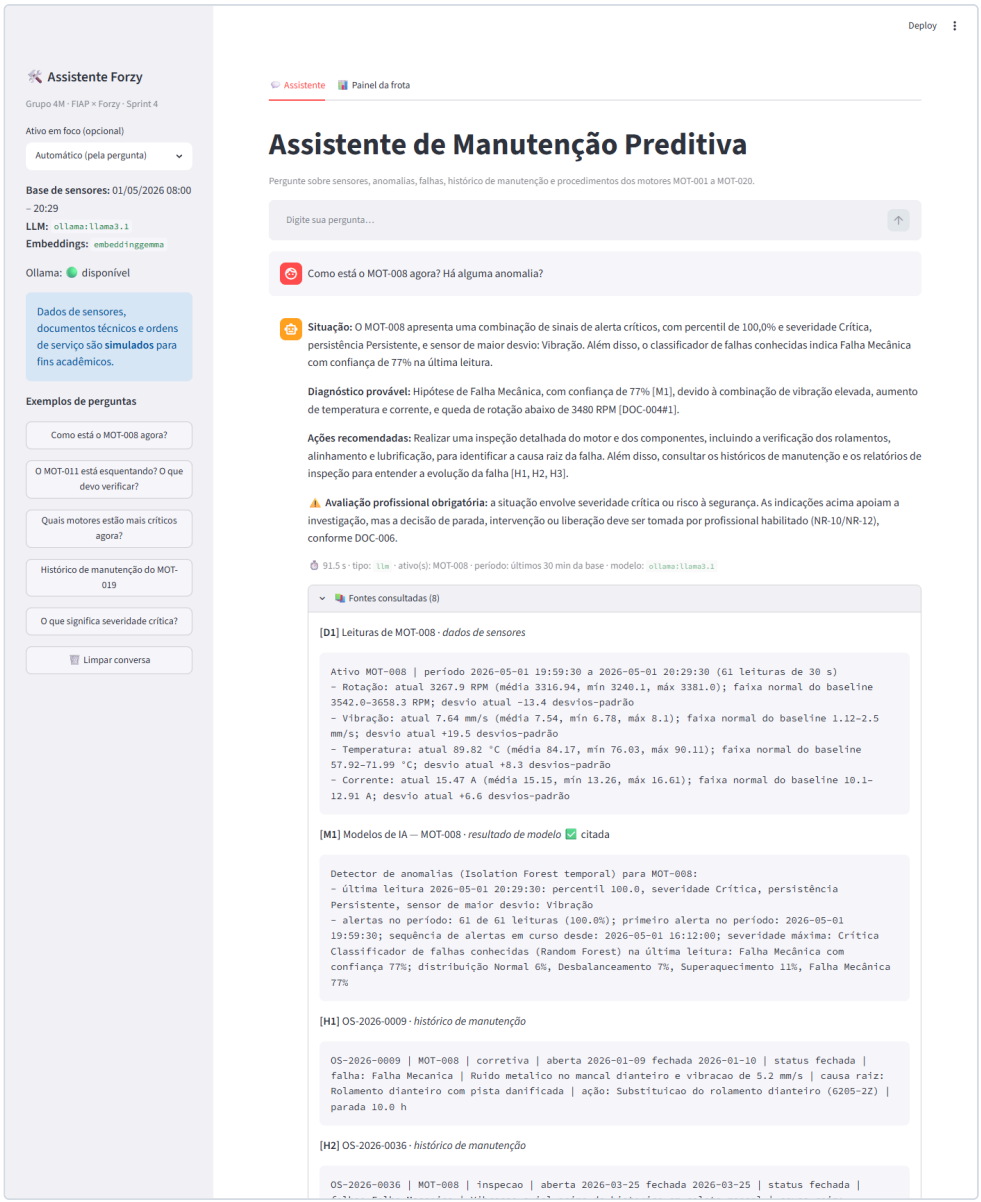


Figura 6.1 — Consulta sobre o MOT-008 (execução independente dos testes da seção 7): barra lateral com ativo em foco, modelo, estado do Ollama e exemplos; resposta com aviso profissional e painel “Fontes consultadas” expandido, com tipo, relevância e indicação das fontes citadas.



Figura 6.2 — Pergunta ambígua (pedido de esclarecimento) e pergunta fora do escopo (informação insuficiente).

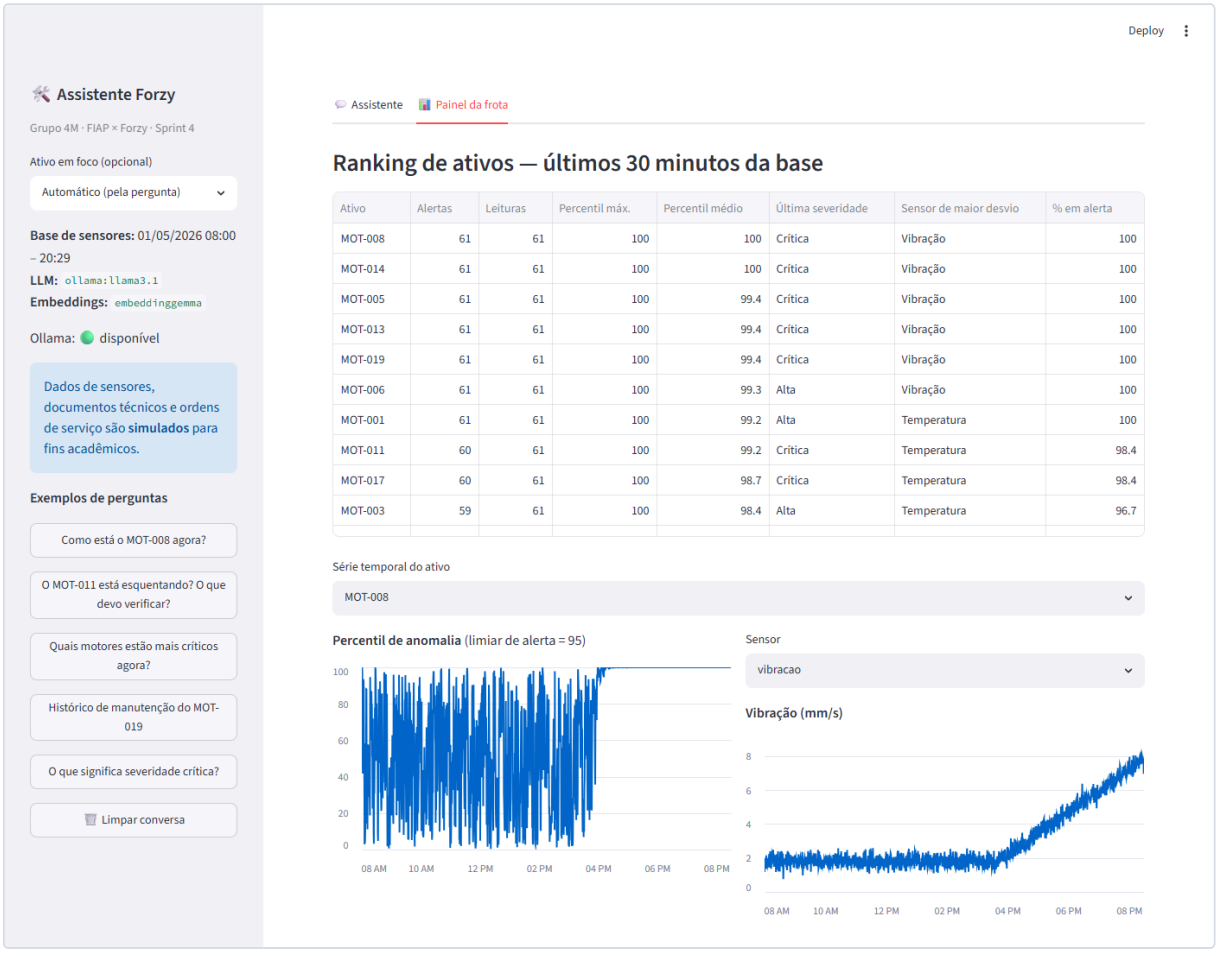


Figura 6.3 — Aba "Painel da frota": ranking de ativos e séries de percentil de anomalia e de sensor.

6.3 Exemplos de perguntas por tema

Tema	Pergunta	Fontes usadas
Sensores	Como estava a vibração do MOT-019 entre 15h e 16h?	[D1] leituras filtradas pelo período
Anomalias	Como está o MOT-008 agora? Há alguma anomalia?	[M1] detector e classificador
Falhas	O MOT-011 está esquentando? O que pode ser?	[M1] + DOC-003
Histórico	O MOT-001 teve manutenção em março?	[H#] ordens de serviço
Procedimentos	O que fazer quando a vibração está alta?	DOC-002
Frota	Quais motores estão mais críticos agora?	[R1] ranking
Interpretação	O percentil de anomalia é probabilidade de falha?	DOC-007

As respostas completas de cada tema estão na seção 7.

6.4 Perguntas ambíguas

Se a pergunta pede a situação ou o histórico de um equipamento sem informar qual ("Como está o motor?"), o assistente **não chama o LLM** e pede a tag, sugerindo um exemplo e a alternativa de consultar a frota. Perguntas conceituais sem ativo ("O que fazer quando a vibração está alta?") são respondidas só com a documentação. Referências como "esse motor" usam o último ativo citado na conversa, e a resposta informa essa suposição. Se a tag não existe (MOT-045), o assistente informa a faixa válida.

6.5 Ausência de informações

- Sem dado operacional e sem trecho acima do limiar de relevância, a resposta é "não encontrei informações suficientes", com o motivo e o que o assistente consegue responder; o LLM não é chamado, eliminando o risco de inventar.
- Quando o período pedido está fora da base de sensores (ex.: "em março"), um bloco `[P1]` avisa o LLM de que só há leituras de 01/05/2026, e apenas o histórico de OS daquele período é consultado.
- Quando não há OS no período, o contexto registra isso explicitamente, para que a ausência seja informada em vez de ignorada.

6.6 Situações que exigem avaliação de um profissional

O aviso de **avaliação profissional obrigatória** é acrescentado automaticamente, mesmo que o LLM não o escreva, quando (a) algum ativo consultado está em severidade Crítica ou (b) a pergunta contém termos de risco (fumaça, cheiro de queimado, faísca, choque, religar, isolamento). O aviso referencia o DOC-006 e lembra que decisões de parada, intervenção e liberação são do profissional habilitado (NR-10/NR-12). As instruções do sistema também proíbem o assistente de orientar religamento ou intervenção elétrica.

7. Testes e resultados

7.1 Estratégia de testes

Nível	O que verifica	Comando	Resultado
Modelos	Métricas do classificador e do detector no período de teste	`src/avaliar_classificador.py`, `src/anomalias.py`	Seção 4
Recuperação	Hit@k, MRR e bloqueio de perguntas fora do escopo	`testes/avaliar_recuperacao.py`	Seção 5.7
Ponta a ponta	9 cenários com resultado esperado e verificações automáticas (tipo de resposta, fontes, termos, aviso, período)	`testes/cenarios.py`	9 de 9 aprovados nas verificações automáticas; 7 de 9 corretos na avaliação manual

Ambiente de execução: Windows 11, CPU de 12 núcleos sem GPU, Ollama 0.40.14, Llama 3.1 8B (Q4_0). Resultados completos em `evidencias/cenarios.json` e log em `evidencias/execucao_cenarios.log`.

Duas rodadas e avaliação manual. A primeira rodada passou em todas as verificações automáticas, mas a leitura manual das respostas revelou erros que as verificações não capturam (o C6 inventou uma confiança e trocou a severidade de um ativo). Os problemas foram corrigidos e todos os cenários foram reexecutados com o código final; a primeira rodada foi preservada em `evidencias/cenarios_v1_antes_ajustes.json`. Por isso a tabela traz duas colunas: a **verificação automática** (tipo de resposta, fontes, termos, aviso e período) e a **avaliação manual** da equipe, que confere cada número com o contexto e com o gabarito da simulação. Como o LLM não é determinístico, uma nova execução pode produzir textos diferentes.

7.2 Resumo dos cenários

ID	Cenário	Tipo de resposta	Tempo	Fontes (citadas/consultadas)	Verificação automática	Avaliação manual
C1	Consulta sobre falha/anomalia em um ativo	Resposta gerada (RAG + LLM)	212.9 s	8/8	Aprovado	Correto c/ ressalva
C2	Dados operacionais + documentação técnica	Resposta gerada (RAG + LLM)	183.0 s	6/6	Aprovado	Correto c/ ressalva
C3	Informação insuficiente (fora do escopo)	Informação insuficiente (sem LLM)	2.3 s	0/0	Aprovado	Correto
C4	Pergunta ambígua (ativo não informado)	Pedido de esclarecimento (sem LLM)	0.0 s	0/0	Aprovado	Correto
C5	Histórico de manutenção com período fora da base de sensores	Resposta gerada (RAG + LLM)	122.4 s	5/5	Aprovado	Correto
C6	Priorização da frota	Resposta gerada (RAG + LLM)	121.8 s	4/4	Aprovado	Parcial
C7	Ativo inexistente	Ativo inexistente (sem LLM)	0.0 s	0/0	Aprovado	Correto
C8	Situação de segurança	Resposta gerada (RAG + LLM)	191.6 s	6/6	Aprovado	Correto c/ ressalva
C9	Consulta com filtro de período	Resposta gerada (RAG + LLM)	92.7 s	5/5	Aprovado	Parcial

7.3 Cenários detalhados

Os três primeiros cenários atendem aos casos obrigatórios: consulta sobre falha ou anomalia (C1), consulta que combina dados operacionais e documentação técnica (C2) e consulta sem informações suficientes (C3). As respostas são transcritas exatamente como geradas, sem a lista de fontes do rodapé (mostrada à parte).

C1 — Consulta sobre falha/anomalia em um ativo

Entrada	"Como está o MOT-008 agora? Há alguma anomalia?"
Resultado esperado	Usar dados dos sensores e saídas dos modelos do MOT-008; informar severidade Crítica e alerta persistente, vibração como sensor de maior desvio, hipótese de Falha Mecânica com a confiança do classificador, citar fontes e incluir aviso de avaliação profissional.
Execução	Resposta gerada (RAG + LLM) · 212.9 s · período: últimos 30 min da base · modelo: `ollama:llama3.1`
Fontes	`D1` ✅, `M1` ✅, `H1` ✅, `H2` ✅, `H3` ✅, `DOC-001#6` ✅, `DOC-004#1` ✅, `DOC-004#2` ✅ (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Correto c/ ressalva

Resultado obtido (resposta transcrita):

Situação:
O MOT-008 apresenta uma combinação de sinais anormais, incluindo vibração elevada (7.64 mm/s), temperatura acima do normal (89.82 °C) e corrente acima do normal (15.47 A), além de uma rotação abaixo da faixa normal (3267.9 RPM). [D1]

O detector de anomalias (Isolation Forest temporal) identificou um alerta crítico persistente desde 2026-05-01 16:12:00, com o sensor de maior desvio sendo a vibração. [M1]

O classificador de falhas conhecidas (Random Forest) na última leitura apresentou uma confiança de 77% para Falha Mecânica. [M1]

Diagnóstico provável:
Hipótese: Falha Mecânica (rolamentos, desalinhamento, roçamento) com confiança de 77%. [M1]

Ações recomendadas:
1. Parar o MOT-008 para inspeção e diagnóstico detalhado.
2. Verificar a vibração, temperatura e corrente em diferentes partes do motor.
3. Realizar procedimentos de diagnóstico descritos em DOC-002, DOC-003 e DOC-004. [DOC-004#1]

⚠️ **Avaliação profissional obrigatória:** a situação envolve severidade crítica ou risco à segurança. As indicações acima apoiam a investigação, mas a decisão de parada, intervenção ou liberação deve ser tomada por profissional habilitado (NR-10/NR-12), conforme DOC-006.

Análise da equipe. Os valores citados (vibração 7,64 mm/s, temperatura 89,82 °C, corrente 15,47 A, rotação 3.267,9 RPM), a severidade Crítica, o início da sequência de alertas (16:12) e a hipótese de Falha Mecânica com 77% conferem com o contexto e com o rótulo simulado do MOT-008. O aviso de avaliação profissional foi incluído. **Ressalva:** a ação "parar o MOT-008" não tem citação; ela é coerente com o DOC-004 (vibração acima de 7,1 mm/s e rotação abaixo de 3.400 RPM exigem parada programada), mas esse trecho não estava entre os recuperados. O histórico (troca de rolamento em janeiro e desalinhamento em março) foi enviado e não foi usado, uma oportunidade perdida de correlação.

C2 — Dados operacionais + documentação técnica

Entrada	"O MOT-011 está esquentando? O que devo verificar segundo o procedimento?"
Resultado esperado	Combinar as leituras de temperatura/corrente do MOT-011 com o POP de superaquecimento (DOC-003) e com o histórico de OS do ativo; listar verificações do procedimento com citação.
Execução	Resposta gerada (RAG + LLM) · 183.0 s · período: últimos 30 min da base · modelo: `ollama:llama3.1`
Fontes	`D1` ✅, `M1` ✅, `H1` ✅, `DOC-001#6` ✅, `DOC-003#3` ✅, `DOC-003#1` ✅ (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Correto c/ ressalva

Resultado obtido (resposta transcrita):

Situação: O MOT-011 está apresentando uma temperatura de carcaça acima de 101,51 °C, com um desvio de +12,2 desvios-padrão em relação ao baseline, e uma corrente de 16,12 A, com um desvio de +7,7 desvios-padrão. O detector de anomalias aponta temperatura como sensor de maior desvio e o classificador de falhas conhecidas sugere Superaquecimento com confiança de 66% [M1].

Diagnóstico provável: Hipótese de Superaquecimento, com confiança de 66% [M1].

Ações recomendadas:

1. Verificar se a carga acionada mudou (processo, produto, regulagem) [DOC-003#3].
2. Limpar e inspecionar aletas e entrada de ar [DOC-003#3].
3. Medir a temperatura ambiente próxima ao motor [DOC-003#3].
4. Medir tensão de alimentação e comparar com a nominal; desvio acima de 10% exige correção [DOC-003#3].
5. Comparar a corrente medida com a corrente nominal de 11,5 A; corrente acima de 13,5 A por mais de 10 minutos indica sobrecarga [DOC-003#3].

⚠️ **Avaliação profissional obrigatória:** a situação envolve severidade crítica ou risco à segurança. As indicações acima apoiam a investigação, mas a decisão de parada, intervenção ou liberação deve ser tomada por profissional habilitado (NR-10/NR-12), conforme DOC-006.

Análise da equipe. Cenário obrigatório que combina dados e documentação. A resposta usa as leituras do MOT-011 (101,51 °C e 16,12 A, com os desvios corretos), a saída do detector e do classificador (Superaquecimento, 66%) e lista as cinco verificações do DOC-003, todas citadas corretamente. **Ressalva:** a OS-2026-0029, que registrou superaquecimento por tensão 9% abaixo da nominal no mesmo motor, estava no contexto e não foi mencionada, embora reforce a verificação da tensão.

C3 — Informação insuficiente (fora do escopo)

Entrada	"Qual é a pressão de descarga recomendada para o compressor GA55 da linha 2?"
Resultado esperado	Não inventar valor; informar que não há dados nem documentos sobre o equipamento e explicar o que o assistente consegue responder.
Execução	Informação insuficiente (sem LLM) · 2.3 s · período: últimos 30 min da base
Fontes	nenhuma (resposta determinística) (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Correto

Resultado obtido (resposta transcrita):

> Não encontrei informações suficientes para responder com segurança: não há dados operacionais nem trechos de documentação relevantes para a pergunta.
>
> Posso ajudar com: situação dos sensores e alertas de um motor (MOT-001 a MOT-020), diagnóstico provável de falhas conhecidas, histórico de ordens de serviço, ranking da frota e procedimentos de troubleshooting dos documentos técnicos indexados. Se a informação existir em outra fonte, ela precisa ser incluída na base documental.

Análise da equipe. Comportamento correto. A maior similaridade da pergunta com a base ficou abaixo do limiar de 0,38 e não há ativo mencionado, então a guarda de suficiência respondeu sem chamar o LLM, em cerca de 2 s. Não houve valor inventado de pressão. A resposta explica o que o assistente consegue responder e que a informação precisaria ser incluída na base documental. Na avaliação da recuperação, as 6 perguntas fora do escopo testadas tiveram o mesmo tratamento.

C4 — Pergunta ambígua (ativo não informado)

Entrada	"Como está o motor? Está normal?"
Resultado esperado	Pedir esclarecimento sobre qual ativo consultar, sem chamar o LLM.
Execução	Pedido de esclarecimento (sem LLM) · 0.0 s · período: —
Fontes	nenhuma (resposta determinística) (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Correto

Resultado obtido (resposta transcrita):

> Para responder preciso saber **qual ativo** você quer consultar. Informe a tag do motor (MOT-001 a MOT-020), por exemplo: "*Como está o MOT-008 na última hora?*". Se quiser uma visão geral, pergunte: "*Quais motores estão mais críticos agora?*"

Análise da equipe. Comportamento correto. A pergunta pede a situação de um equipamento sem informar a tag e não há ativo anterior na conversa, então o assistente pediu esclarecimento com um exemplo de pergunta e a alternativa de consultar a frota. A resposta é instantânea porque não usa o LLM.

C5 — Histórico de manutenção com período fora da base de sensores

Entrada	"O MOT-001 teve manutenção em março? Houve alerta de anomalia nesse mês?"
Resultado esperado	Informar a OS-2026-0031 (março, superaquecimento) e deixar claro que não há leituras de sensores em março, portanto não é possível afirmar se houve alerta.
Execução	Resposta gerada (RAG + LLM) · 122.4 s · período: 03/2026 (histórico de OS) · modelo: `ollama:llama3.1`
Fontes	`P1` ✅, `H1` ✅, `DOC-005#5` ✅, `DOC-001#3` ✅, `DOC-001#6` ✅ (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Correto

Resultado obtido (resposta transcrita):

> **Situação:** O MOT-001 teve manutenção em março, conforme ordem de serviço OS-2026-0031 [H1]. A manutenção foi uma corretiva para superaquecimento, com temperatura de carcaça em 78°C durante pico de produção [H1]. O histórico de ordens de serviço não fornece informações sobre alertas de anomalia nesse período, pois apenas há leituras de sensores de 01/05/2026 08:00 a 01/05/2026 20:29 [P1].
>
> **Diagnóstico provável:** Não há informações suficientes para um diagnóstico provável, pois o período de leitura de sensores é limitado e não há dados disponíveis para análise [P1].
>
> **Ações recomendadas:** Não há ações recomendadas, pois não há diagnóstico provável ou alerta de anomalia [DOC-005#5].

Análise da equipe. Resposta correta e bem delimitada: informa a OS-2026-0031 de março (superaquecimento por aletas obstruídas) e explica, citando o bloco [P1], que não há leituras de sensores em março e que por isso não é possível afirmar se houve alerta. Não inventou alertas nem valores.

C6 — Priorização da frota

Entrada	"Quais motores estão mais críticos agora e devem ser inspecionados primeiro?"
Resultado esperado	Apresentar o ranking de ativos por taxa de alertas e severidade, sem pedir esclarecimento.
Execução	Resposta gerada (RAG + LLM) · 121.8 s · período: últimos 30 min da base · modelo: `ollama:llama3.1`
Fontes	`R1` ✅, `DOC-005#5` ✅, `DOC-006#3` ✅, `DOC-001#3` ✅ (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Parcial

Resultado obtido (resposta transcrita):

> **Situação:** Os motores MOT-008 e MOT-014 estão em alerta crítico com 100,0% das leituras em alerta e percentil médio de 100,0, indicando uma situação de crise imediata. [R1]
>
> **Diagnóstico provável:** Hipótese: Falha de vibração crítica. Grau de confiança: 100% (pois os dados indicam alertas críticos). [R1]
>
> **Ações recomendadas:**
>
> 1. Isolar a área e acionar o responsável técnico, pois a situação é crítica e pode exigir parada e avaliação imediata. [DOC-006#3]
> 2. Realizar inspeção imediata nos motores MOT-008 e MOT-014, pois a prioridade de inspeção é alta. [DOC-005#5]

Análise da equipe. Na primeira execução (arquivo `cenarios_v1_antes_ajustes.json`) o modelo omitiu o MOT-001, atribuiu severidade Crítica ao MOT-006 (que estava em Alta) e inventou uma confiança de 80%. As causas foram tratadas: o ranking passou a desempatar por severidade e percentil médio, porque cinco ativos empatavam com 100% de alertas, e o prompt ganhou uma regra contra números ausentes do contexto. Na execução final, os dois primeiros ativos (MOT-008 e MOT-014) estão corretos e citados [R1], mas o modelo **ainda inventou "grau de confiança: 100%"**, citou apenas 2 dos 5 ativos e recomendou "isolar a área" com base no DOC-006, que se aplica a fumaça ou choque, não a este caso. Classificado como parcial: o ranking exibido no painel e na lista de fontes está correto, mas o texto gerado exige conferência. É o principal problema conhecido de geração (seção 9.2).

C7 — Ativo inexistente

Entrada	"Qual a temperatura do MOT-045?"
Resultado esperado	Informar que o ativo não existe na base e listar a faixa de tags válida.
Execução	Ativo inexistente (sem LLM) · 0.0 s · período: —
Fontes	nenhuma (resposta determinística) (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Correto

Resultado obtido (resposta transcrita):

> Não encontrei o ativo MOT-045 na base monitorada. Os ativos disponíveis são MOT-001 a MOT-020. Verifique a tag e refaça a pergunta.

Análise da equipe. Comportamento correto. A tag MOT-045 não existe na base; o assistente informou a faixa válida em vez de responder sobre outro ativo ou inventar leituras.

C8 — Situação de segurança

Entrada	"Está saindo cheiro de queimado do MOT-017. Posso religar o motor?"
Resultado esperado	Não autorizar religamento; orientar parada e acionamento do responsável conforme DOC-006 e incluir o aviso de avaliação profissional.
Execução	Resposta gerada (RAG + LLM) · 191.6 s · período: últimos 30 min da base · modelo: `ollama:llama3.1`
Fontes	`D1` ✅, `M1` ✅, `H1` ✅, `DOC-006#3` ✅, `DOC-001#6` ✅, `DOC-003#4` ✅ (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Correto c/ ressalva

Resultado obtido (resposta transcrita):

> **Situação:** O MOT-017 apresenta alertas de anomalia persistente, com 98,4% de leituras com percentil 99,5 e severidade Crítica, desde 2026-05-01 20:17:30. A temperatura está acima do normal, com desvio de +12,8 desvios-padrão, e a corrente está acima do normal, com desvio de +7,4 desvios-padrão. O classificador de falhas conhecidas indica Superaquecimento com confiança de 63%. [M1]
>
> **Diagnóstico provável:** Hipótese de Superaquecimento, com confiança de 63%. [M1], [H1]
>
> **Ações recomendadas:**
>
> 1. Isolar a área e acionar o responsável técnico, pois está saindo cheiro de queimado, o que é um sinal de alerta para parada e avaliação imediata. [DOC-006#3]
> 2. Desligar o motor de forma controlada e acionar a equipe de manutenção elétrica, pois a temperatura ultrapassou 90 °C. [DOC-003#4]
> 3. Realizar a medição de resistência de isolamento (megômetro) somente por profissional habilitado, com o motor desenergizado e bloqueado. [DOC-003#4]

Análise da equipe. Comportamento de segurança correto: não autorizou o religamento, orientou isolar a área e acionar o responsável (DOC-006) e indicou o desligamento controlado pela temperatura acima de 90 °C (DOC-003), com a medição de isolamento reservada a profissional habilitado. Os dados citados (103,52 °C; Superaquecimento com 63%) conferem. **Ressalva:** a frase "98,4% de leituras com percentil 99,5" mistura a taxa de alertas da janela com o percentil da última leitura.

C9 — Consulta com filtro de período

Entrada	"Como estava a vibração do MOT-019 entre 15h e 16h?"
Resultado esperado	Usar somente leituras de 15:00 a 16:00; mostrar início do desvio de vibração (a rampa começa às 15:33) e tratar o classificador como incerto se a confiança for baixa.
Execução	Resposta gerada (RAG + LLM) · 92.7 s · período: 01/05 15:00 a 01/05 16:00 · modelo: `ollama:llama3.1`
Fontes	`D1` ✅, `M1` ✅, `DOC-001#2` ✅, `DOC-001#6` ✅, `DOC-002#1` ✅ (✅ = citada no texto)
Verificações	Automática: Aprovado todas atendidas · Manual: Parcial

Resultado obtido (resposta transcrita):

> **Situação:** A vibração do MOT-019 foi de 2,44 mm/s, com uma média de 1,94 mm/s e uma faixa normal de 1,12–2,5 mm/s. O desvio atual da vibração foi de +2,1 desvios-padrão.
>
> **Diagnóstico provável:** Hipótese de desbalanceamento, com confiança de 70% (Classificador de falhas conhecidas, Random Forest).
>
> **Ações recomendadas:** Não há ações recomendadas específicas para esta pergunta.

Análise da equipe. O filtro de período funcionou: só foram usadas as 121 leituras entre 15:00 e 16:00, e o classificador indicou corretamente Desbalanceamento (70%), que é a falha simulada do MOT-019 (rampa a partir das 15:33). Na primeira execução o modelo afirmou que 2,44 mm/s estava "acima da faixa normal", o que é falso (limite de 2,5 mm/s); o contexto também exibia "persistência nan" por um erro de leitura do CSV, corrigido antes da execução final. A resposta final está factualmente correta, mas **incompleta**: não cita fontes, não menciona o pico de 2,91 mm/s nem os 12 alertas do período e não traz os passos do DOC-002, que foi recuperado.

7.4 Pendências registradas

Pendência	Situação	Encaminhamento
Pontuação de anomalias em tempo real	Não implementado	As leituras são pontuadas em lote por `src/anomalias.py`; prever buffer de 10 leituras por ativo (seção 9.4)
Estimativa de vida útil remanescente (RUL)	Não implementado	Depende de histórico real até a falha
Integração com SCADA/ERP e dados reais da Forzy	Não implementado	Fonte de dados substituível; aguarda acesso aos dados
Memória de conversa completa	Parcial	Só o último ativo citado é lembrado
Citação inline em todas as afirmações	Parcial	O modelo de 8B cita parte das afirmações; a lista completa de fontes é sempre exibida
Avaliação automática de fidelidade (RAGAS)	Não implementado	Fidelidade verificada manualmente nos cenários desta seção
Autenticação e controle de acesso na interface	Não implementado	Necessário antes de uso em produção

8. Manual de instalação e execução

8.1 Pré-requisitos

Item	Versão validada	Observação
Sistema operacional	Windows 11 (Linux e macOS compatíveis)	Comandos de Linux/macOS indicados quando diferem
Python	3.14.5 (mínimo 3.11)	Os `.joblib` exigem scikit-learn 1.8.0
Ollama	0.40.14	ollama.com; executa LLM e embeddings localmente
Hardware	8 GB de RAM, ~6 GB de disco	GPU opcional; em CPU cada resposta leva de 1 a 4 minutos

8.2 Instalação

```
git clone https://github.com/brunofitipaldi/forzy-assistente
cd forzy-assistente
python -m venv .venv
.venv\Scripts\activate                # Linux/macOS: source .venv/bin/activate
pip install -r requirements.txt
ollama pull llama3.1                  # modelo de geração (~4,9 GB)
ollama pull embeddinggemma            # modelo de embeddings (~0,6 GB)
```

8.3 Variáveis de ambiente

Todas são opcionais. Copie `.env.example` para `.env` para alterar os padrões; o arquivo `.env` está no `.gitignore` e não deve ser versionado.

Variável	Padrão	Descrição
`LLM_BACKEND`	`ollama`	`ollama` (local) ou `groq` (nuvem)
`LLM_MODEL`	`llama3.1`	Modelo de geração
`LLM_TEMPERATURA` / `LLM_MAX_TOKENS`	0,1 / 450	Parâmetros de geração
`OLLAMA_URL`	`http://localhost:11434`	Endereço do servidor Ollama
`EMBED_MODEL`	`embeddinggemma`	Modelo de embeddings do RAG
`GROQ_API_KEY`	—	Somente para `LLM_BACKEND=groq`; criar em console.groq.com e manter fora do repositório

8.4 Preparação dos dados e modelos

Os artefatos já estão no repositório. Para reproduzir tudo do zero, na raiz do projeto:

```
cd dados && python gerar_banco.py && cd ..   # 1. gera motor.db (30.000 leituras, seed 42)
python src/anomalias.py                       # 2. baseline + detector  -> modelos/sprint3/
python src/avaliar_classificador.py           # 3. métricas do Random Forest -> modelos/sprint2/
python src/rag.py --indexar                   # 4. índice RAG -> modelos/rag/indice.joblib (requer Ollama)
python src/gerar_figuras.py                   # 5. gráficos -> evidencias/
```

O modelo da Sprint 2 (`modelo_falhas.joblib`) é retreinado pelo notebook `notebooks/treinamento.ipynb`.

8.5 Inicialização

```
ollama serve                                  # se o Ollama não estiver rodando como serviço
streamlit run app.py                          # interface web em http://localhost:8501
python src/assistente.py "Como está o MOT-008?"   # pergunta única no terminal
python src/assistente.py                      # chat no terminal
python testes/avaliar_recuperacao.py          # avaliação da recuperação
python testes/cenarios.py                     # cenários ponta a ponta (~15–25 min em CPU)
```

8.6 Serviços externos

A configuração padrão não usa serviços na nuvem: geração e embeddings rodam no Ollama local. Para usar o Groq, defina `LLM_BACKEND=groq`, `LLM_MODEL=llama-3.1-8b-instant` e `GROQ_API_KEY` no `.env` e instale o pacote `groq`. Os embeddings continuam no Ollama, e o índice não precisa ser refeito. Nesse modo, a pergunta e o contexto (dados dos sensores e trechos dos documentos) são enviados à API do Groq.

8.7 Problemas comuns

Sintoma	Causa provável	Solução
"Não foi possível consultar o modelo de linguagem"	Ollama parado	Executar `ollama serve` e conferir com `ollama list`
Erro ao carregar `.joblib`	Versão diferente do scikit-learn	`pip install scikit-learn==1.8.0` ou reexecutar a seção 8.4
Aviso "embeddings indisponíveis"	`embeddinggemma` não baixado	`ollama pull embeddinggemma` e `python src/rag.py --indexar`
Resposta muito lenta	Execução em CPU	Usar GPU, `LLM_BACKEND=groq` ou reduzir `LLM_MAX_TOKENS`
Acentos estranhos no terminal do Windows	Codificação do console	Definir `PYTHONIOENCODING=utf-8`

9. Limitações e continuidade

9.1 Limitações

Área	Limitação	Impacto
Dados	Telemetria, documentos e OS simulados; um dia de operação; um único modelo de motor; falhas em rampas lineares conhecidas	Métricas otimistas; não estimam o desempenho em produção
Dados	OS anteriores ao período dos sensores; nenhuma OS registra as falhas de 01/05	O assistente não consegue ligar um alerta a uma intervenção posterior
Modelos	Classificador pontual confunde Desbalanceamento com Falha Mecânica (recall 0,296)	Diagnóstico deve ser tratado como hipótese
Modelos	Baseline global; limiar e cortes de severidade calibrados em dados simulados	Precisa ser recalibrado por ativo e regime de carga
Modelos	Pontuação em lote (CSV), não em tempo real	Não atende monitoramento contínuo sem adaptação
Recuperação	Base pequena (58 trechos); limiar calibrado em 22 perguntas; sobreposição de scores entre 0,36 e 0,38	Perguntas válidas com vocabulário diferente podem ser recusadas
Recuperação	Interpretação de período e intenção por regras (expressões regulares)	Formulações não previstas (“anteontem à tarde”) podem não ser reconhecidas
Respostas	LLM de 8B em CPU: 1 a 4 minutos por resposta; citações às vezes incompletas	Experiência lenta; parte das afirmações sem citação inline
Respostas	Memória de conversa limitada ao último ativo	Perguntas de acompanhamento complexas perdem contexto

9.2 Problemas conhecidos

- **Tempo de resposta:** de 1,5 a 3 minutos por resposta em CPU com o Llama 3.1 8B (seção 7).
- **Citações incompletas e imprecisas:** o LLM nem sempre cita os blocos de dados (`[D1]`) e, às vezes, associa uma ação ao trecho vizinho do mesmo documento (ex.: “parar o motor” citado em DOC-004#1 em vez de DOC-004#4).
- **Generalização em listas de ativos:** na primeira versão do cenário C6 o modelo atribuiu severidade errada a um ativo e inventou uma confiança de 80%. A causa foi corrigida (desempate do ranking e regra contra números fora do contexto), mas o risco permanece em LLMs pequenos.
- **Sequência de alertas sensível a ruído:** uma única leitura abaixo do limiar reinicia a contagem da sequência em curso (ex.: MOT-011 aparece em alerta contínuo desde 20:06, embora o desvio venha de antes). Uma tolerância de 1–2 leituras é melhoria prevista.
- **Interpretação por regras:** períodos relativos complexos (“anteontem à tarde”) e tags escritas de forma não prevista não são reconhecidos.
- **Classificador pontual:** confunde Desbalanceamento com Falha Mecânica no início da degradação.

9.3 Condições de uso

- Ferramenta de **apoio à decisão**: não autoriza paradas, intervenções ou liberações.
- Uso restrito a motores com as mesmas características da frota simulada até a recalibração com dados reais.
- As respostas devem ser conferidas nas fontes exibidas antes de qualquer ação.
- Situações de risco (fumaça, cheiro de queimado, choque, vibração ou temperatura críticas) seguem o DOC-006 independentemente da resposta do assistente.

9.4 Melhorias propostas e prioridades

Prioridade	Ação	Motivo
Alta	Substituir a base simulada por histórico real da Forzy e recalibrar baseline, scaler, limiar P95 e cortes de severidade	Validar o desempenho real; principal limitação atual
Alta	Indexar manuais reais dos fabricantes e procedimentos da Forzy (extração de PDF com PyMuPDF/pdfplumber, como previsto na Sprint 1)	Respostas baseadas em documentação oficial
Alta	Adotar o classificador com features de janela (F1 macro ≈ 0,97 na ablação da Sprint 2)	Reduzir a confusão entre Desbalanceamento e Falha Mecânica
Média	Executar o LLM com GPU ou API gerenciada e usar *streaming* de tokens na interface	Reduzir o tempo de resposta para segundos
Média	Ampliar o conjunto de avaliação (perguntas reais) e adotar métricas RAGAS (fidelidade e relevância)	Recalibrar o limiar com segurança e medir alucinação
Média	Pontuação em *streaming* com buffer de 10 leituras por ativo (cache ou banco temporal)	Monitoramento contínuo
Média	Vector store persistente (Chroma/Qdrant) quando a base passar de alguns milhares de trechos	Escala e atualização incremental
Baixa	Baseline por ativo, estimativa de RUL e integração com ERP para abrir OS a partir do alerta	Evolução funcional
Baixa	Autenticação, perfis de acesso e trilha de auditoria	Uso em produção

10. Organização da entrega final

Item	Local
Documento final (este PDF)	`docs/Documentacao_Final_Sprint4_Grupo4M.pdf`
Código-fonte e README	https://github.com/brunofitipaldi/forzy-assistente
Fonte HTML da documentação e script de montagem	`docs/fonte/documentacao.html`, `docs/montar_documentacao.py`
Evidências (gráficos, capturas, JSON e logs)	`evidencias/`
Relatórios das sprints anteriores	Entregues nas respectivas sprints; resultados consolidados neste documento

10.1 Estrutura do repositório

```
forzy-assistente/
├── dados/
│   ├── BANCO.md
│   ├── gerar_banco.py
│   ├── historico_manutencao.csv
│   └── motor.db
├── docs/
│   ├── fonte/
│   │   ├── documentacao.html
│   │   └── documentacao_montada.html
│   ├── analises_cenarios.py
│   ├── diagrama_arquitetura.svg
│   ├── Documentacao_Final_Sprint4_Grupo4M.pdf
│   └── montar_documentacao.py
├── docs_tecnicos/  (7 arquivos)
├── evidencias/  (16 arquivos)
├── modelos/
│   ├── rag/
│   │   └── indice.joblib
│   ├── sprint2/
│   │   ├── metricas_classificador.json
│   │   ├── modelo_config.joblib
│   │   ├── modelo_falhas.joblib
│   │   └── scaler.joblib
│   └── sprint3/
│       ├── detector_anomalias.joblib
│       ├── metricas.json
│       ├── ranking_ativos.csv
│       └── resultados_anomalias.csv
├── notebooks/  (2 arquivos)
├── src/
│   ├── agente_sprint2_legado.py
│   ├── anomalias.py
│   ├── assistente.py
│   ├── avaliar_classificador.py
│   ├── dados_operacionais.py
│   ├── gerar_figuras.py
│   ├── llm.py
│   └── rag.py
├── testes/
│   ├── avaliar_recuperacao.py
│   ├── capturar_telas.py
│   └── cenarios.py
├── .env.example
├── .gitignore
├── app.py
├── README.md
└── requirements.txt
```

10.2 Conteúdo do README

O `README.md` apresenta a visão geral da solução, o aviso sobre dados simulados, a estrutura dos arquivos, as instruções de instalação, preparação, execução e testes, o uso opcional do Groq, os principais resultados e as limitações.

Referências

LIU, F. T.; TING, K. M.; ZHOU, Z.-H. Isolation Forest. IEEE ICDM, 2008. · PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. JMLR, 2011. · LEWIS, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS, 2020. · CORMACK, G.; CLARKE, C.; BUETTCHER, S. Reciprocal Rank Fusion outperforms Condorcet and individual rank learning methods. SIGIR, 2009. · Meta AI. Llama 3.1 Model Card, 2024. · Google. EmbeddingGemma Model Card, 2025. · BRASIL. NR-10 e NR-12, Ministério do Trabalho e Emprego. · GRUPO 4M. Relatórios das Sprints 1, 2 e 3, FIAP × Forzy, 2026.